

模式识别

Pattern Recognition

第5讲 统计分类器及其学习I

1 概率论与统计学习

2 贝叶斯决策理论

3 高斯分布的贝叶斯分类器

概率论与统计学习

判别式模型 (Discriminative Model)

将 \mathbf{x} 看做特征空间中的点

构建判别函数 $g(\mathbf{x})$ 来决定 \mathbf{x} 属于哪个类别

关键在于计算 \mathbf{x} 与训练样本 \mathbf{x}_i 间的相对位置 (内积) 关系

产生式模型 (Generative Model)

将 \mathbf{x} 看做随机变量

根据 \mathbf{x} 属于各类别 ω_i 的概率大小 $P(\omega_i|\mathbf{x})$, 来决定其类别

关键在于计算不同类别产生 “待识别模式” 的概率 $P(\mathbf{x}|\omega_i)$


常用的概率表示形式

先验概率: $P(\omega_i)$

后验概率: $P(\omega_i|\mathbf{x})$


类条件概率: $P(\mathbf{x}|\omega_i)$

贝叶斯公式:
$$P(\omega_i|\mathbf{x}) = \frac{P(\mathbf{x}|\omega_i)P(\omega_i)}{P(\mathbf{x})}$$



- 类条件概率密度

Class-conditional probability density




- $P(\omega_1)=2/3, P(\omega_2)=2/3$ 时的后验概率密度

统计学习模型

S: 目标算子 (训练器)

将 \mathbf{x} 变换成 ω , 存在、不变、未知。



G: 数据 (实例) 发生器

依据某一固定但未知的概率分布函数 $F(\mathbf{x})$, 独立同分布地产生向量 \mathbf{x}


$$F(\mathbf{x}, \omega) = F(\mathbf{x})F(\omega|\mathbf{x})$$

LM: 学习机器

观测训练集 $(\mathbf{x}_1, \omega_1) \cdots (\mathbf{x}_\ell, \omega_\ell)$
构造算子, 预测特定向量 \mathbf{x}_i 的响应 ω_i

学习过程: 从给定的函数集中寻找一个适当的函数

统计学习模型



学习目标:

1, 模仿训练器的算子:

对给定的发生器 G , 预测训练器 S 的输出

2, 辨识训练器算子:

构造一个非常接近训练器算子 S 的算子

1 概率论与统计学习

2 贝叶斯决策理论

3 高斯分布的贝叶斯分类器

贝叶斯决策理论

各类别总体的概率分布已知
要决策分类的类别数一定

已知：分类问题有 c 个类别 $\omega_1, \omega_2, \dots, \omega_c$

各类别的先验概率 $P(\omega_i)$

各类条件概率密度函数 $P(\mathbf{x}|\omega_i)$

决策：对于特征空间中观测到的向量 $\mathbf{x} = [x_1, x_2, \dots, x_d]^t$
应该将 \mathbf{x} 分到哪一类？

错误率最小 \longrightarrow 风险最小

贝叶斯决策理论

- 基于最小错误率的贝叶斯决策
- 基于最小风险的贝叶斯决策
- Neyman-Pearson决策规则: 限定一类错误率, 最小化另一类错误率
- 极小化极大准则: 先验概率 $P(\omega_i)$ 未知的情况下, 使最大可能的风险最小化

两类问题的错误率

- 观察到特征 \mathbf{x} 时作出判别的错误率:


$$P(\text{error}|\mathbf{x}) = \begin{cases} P(\omega_1|\mathbf{x}), & \text{判定 } \omega_2 \\ P(\omega_2|\mathbf{x}), & \text{判定 } \omega_1 \end{cases}$$

- 两类问题最小错误率判别准则:


$$\begin{cases} \text{如果 } P(\omega_1|\mathbf{x}) > P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_1 \\ \text{如果 } P(\omega_1|\mathbf{x}) < P(\omega_2|\mathbf{x}), & \mathbf{x} \in \omega_2 \end{cases}$$



最大后验概率



贝叶斯分类器的错误率估计



多类问题最小错误率

- 判别 \mathbf{x} 属于 ω_i 的错误率:

$$P(\text{error}|\mathbf{x}) = \sum_{j \neq i} P(\omega_j|\mathbf{x}) = 1 - P(\omega_i|\mathbf{x})$$

- 判别准则为:

$$i = \arg \max_{1 \leq j \leq c} P(\omega_j|\mathbf{x}), \text{ 则: } \mathbf{x} \in \omega_i$$

最大后验概率

贝叶斯最小错误率准则

$$P(\omega_j | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_j) P(\omega_j)}{p(\mathbf{x})}$$

$$g_j(\mathbf{x}) = p(\mathbf{x} | \omega_j) P(\omega_j)$$

$$g_j(\mathbf{x}) = \ln p(\mathbf{x} | \omega_j) + \ln P(\omega_j)$$

Bayes判别准则:

$$i = \arg \max_{1 \leq j \leq c} g_j(\mathbf{x}) \quad , \quad \text{则} \quad \mathbf{x} \in \omega_i$$

例:

对一大批人进行癌症普查，设 ω_1 类代表患癌症， ω_2 类代表正常人。已知先验概率：

$$P(\omega_1) = 0.005, P(\omega_2) = 0.995$$

以一个化验结果作为特征 x : {阳性, 阴性}, 患癌症的人和正常人化验结果为阳性的概率分别为：

$$P(x = \text{阳性} | \omega_1) = 0.95, P(x = \text{阳性} | \omega_2) = 0.01$$

现有一人化验结果为阳性，问此人是否患癌症？

$$\text{最小错误率准则: } g_j(\mathbf{x}) = p(\mathbf{x} | \omega_j) P(\omega_j)$$

基于最小风险的贝叶斯决策

判断某人是正常($\omega_{\text{正}}$)还是患者($\omega_{\text{患}}$),将出现以下情况:

| 实际类别 ω_i | 决策类别 ω_j | 风险因子 λ_{ij} |
|-----------------|-----------------|---------------------|
| 正常人 | 正常人 | 0 |
| 正常人 | 患者 | 0.25 |
| 患者 | 正常人 | 1 |
| 患者 | 患者 | 0 |

何种决策风险最小?

做出正常判决的风险: $R_{\text{正}}(\mathbf{x}) = \lambda_{\text{正} \rightarrow \text{正}} P(\omega_{\text{正}} | \mathbf{x}) + \lambda_{\text{患} \rightarrow \text{正}} P(\omega_{\text{患}} | \mathbf{x})$

做出患病判决的风险: $R_{\text{患}}(\mathbf{x}) = \lambda_{\text{正} \rightarrow \text{患}} P(\omega_{\text{正}} | \mathbf{x}) + \lambda_{\text{患} \rightarrow \text{患}} P(\omega_{\text{患}} | \mathbf{x})$

做出j类判决的风险:
$$R_j(\mathbf{x}) = \sum_{i=1}^c \lambda_{ij} P(\omega_i | \mathbf{x})$$

——计算各类决策风险, 选则最小风险对应的决策

最小平均风险准则贝叶斯分类器

- 有 c 个类别 $\omega_1, \omega_2, \dots, \omega_c$, 将 ω_i 类的样本判别为 ω_j 类的代价为 λ_{ij} 。
- 将未知模式 \mathbf{x} 判别为 ω_j 类的平均风险为：

$$\gamma_j(\mathbf{x}) = \sum_{i=1}^c \lambda_{ij} \underbrace{P(\omega_i | \mathbf{x})}_{= \frac{p(\mathbf{x} | \omega_j) P(\omega_j)}{p(\mathbf{x})}}$$

- 利用Bayes公式:

$$\gamma_j(\mathbf{x}) = \sum_{i=1}^c \lambda_{ij} \underbrace{P(\mathbf{x} | \omega_i) P(\omega_i)}$$

- 构造判别函数：

$$g_j(\mathbf{x}) = -\gamma_j(\mathbf{x})$$

例

- 对一大批人进行癌症普查，设 ω_1 类代表患癌症， ω_2 类代表正常人。已知先验概率：

$$P(\omega_1) = 0.004, P(\omega_2) = 0.996$$

以一个化验结果作为特征 x ：{阳性，阴性}，患癌症的人和正常人化验结果为阳性的概率分别为：

$$P(x = \text{阳性} | \omega_1) = 0.96, P(x = \text{阳性} | \omega_2) = 0.01$$

判别代价： $\lambda_{11} = 0, \lambda_{22} = 0, \lambda_{12} = 95, \lambda_{21} = 15$

现有一人化验结果为阳性，问此人是否患癌症？

贝叶斯最小风险判别：

$$g_j(\mathbf{x}) = -\gamma_j(\mathbf{x}) \quad \gamma_j(\mathbf{x}) = \sum_{i=1}^c \lambda_{ij} P(\mathbf{x} | \omega_i) P(\omega_i)$$

贝叶斯决策论——举例

决策问题：

判别类别 $\{\omega_1, \dots, \omega_c\}$ 正常人、癌症早期，癌症晚期

治疗行为 $\{\alpha_1, \dots, \alpha_a\}$ ：不治疗、保守治疗、手术治疗、化疗

风险函数： 在类别状态 ω_j 时，采取行动 α_i 的风险（预期损失）

$$\lambda_{\text{手术, 癌症早期}} = \lambda(\alpha_{\text{手术}} | \omega_{\text{癌症早期}})$$

条件风险： 观察到某人体检特征 \mathbf{x} ，采取行动 $\alpha_{\text{手术}}$ 的损失期望

$$\begin{aligned} R(\alpha_{\text{手术}} | \mathbf{x}) &= \lambda(\alpha_{\text{手术}} | \omega_{\text{正常}}) P(\omega_{\text{正常}} | \mathbf{x}) \\ &\quad + \lambda(\alpha_{\text{手术}} | \omega_{\text{早期}}) P(\omega_{\text{早期}} | \mathbf{x}) \\ &\quad + \lambda(\alpha_{\text{手术}} | \omega_{\text{晚期}}) P(\omega_{\text{晚期}} | \mathbf{x}) \\ &= \sum_{j=1}^c \lambda(\alpha_i | \omega_j) P(\omega_j | \mathbf{x}) \end{aligned}$$

对某人 \mathbf{x} 进行手术的预期风险

贝叶斯决策论

引入一般的损失函数来替代误差概率

$\{\omega_1, \dots, \omega_c\}$ 表示有限的c个类别集

$\{\alpha_1, \dots, \alpha_a\}$ 表示有限的a种可能采取的行为集

风险函数 $\lambda_{ij} = \lambda(\alpha_i | w_j)$

在类别状态 w_j 时, 采取行动 α_i 的风险 (预期损失)

条件风险: 观察模式为 \mathbf{x} 的条件下, 采取行动 α_i 的损失期望

$$R(\alpha_i | \mathbf{x}) = E[\lambda(\alpha_i | w_j)] = \sum_{j=1}^c \lambda(\alpha_i | w_j) P(w_j | \mathbf{x})$$

将模式 \mathbf{x} 判属某类所造成的损失的条件数学期望,
反映对未知 \mathbf{x} 采取一个判决行动 $\alpha(\mathbf{x})$ 所付出的代价

贝叶斯决策论

对于 \mathbf{x} 的不同观察值，采取决策 α_i 时，其条件风险的大小是不同的。所以，究竟采取哪一种决策将随 \mathbf{x} 的取值而定。决策 α 可以看成随机向量 \mathbf{x} 的函数，记为 $\alpha(\mathbf{x})$

期望风险 R （总风险、条件期望损失）：

$$R = \int R(\alpha(\mathbf{x})|\mathbf{x})p(\mathbf{x})d\mathbf{x}$$

$d\mathbf{x}$ 是特征空间的体积元，积分在整个特征空间进行。

在整个特征空间中定义期望风险 R ，反映对整个特征空间所有 \mathbf{x} 的取值采取相应的决策 $\alpha(\mathbf{x})$ 所带来的平均风险。

贝叶斯决策论

基本思想：统计意义上使由于误判而蒙受的损失最小。


条件风险最小判决：对 \mathbf{x} 采取决策 α 使其条件风险最小。

$$\alpha = \arg \min_{\alpha_i} R(\alpha_i | \mathbf{x})$$

贝叶斯风险：对所有的 \mathbf{x} 作出决策时，均进行条件风险最小化，总的期望风险 R 也最小，称为贝叶斯风险，记为 R^* 。

R^* ：最小化后的总风险值，可获得的最优结果

误差概率



$$P(\mathbf{x} \in \mathcal{R}_1, \omega_2) = P(\mathbf{x} \in \mathcal{R}_1 | \omega_2) \cdot P(\omega_2)$$

$$P(\mathbf{x} \in \mathcal{R}_2, \omega_1) = P(\mathbf{x} \in \mathcal{R}_2 | \omega_1) \cdot P(\omega_1)$$

最小风险贝叶斯决策

如果： $R(\alpha_k | x) = \min_{i=1,2,\dots,a} R(\alpha_i | x)$

则： $a = a_k$

$x \in \omega_k$

最小风险贝叶斯决策必须要有合适的损失函数。实际工作中要列出合适的决策表很不容易，往往要根据所研究的具体问题，分析错误决策造成损失的严重程度来确定。

两类问题的最小风险贝叶斯决策

$$\frac{R(\alpha_1 | \mathbf{x})}{R(\alpha_2 | \mathbf{x})} < 1 \Rightarrow \mathbf{x} \in \omega_1$$

$$R(\alpha_1 | \mathbf{x}) = \lambda_{11}P(\omega_1 | \mathbf{x}) + \lambda_{12}P(\omega_2 | \mathbf{x})$$


$$R(\alpha_2 | \mathbf{x}) = \lambda_{21}P(\omega_1 | \mathbf{x}) + \lambda_{22}P(\omega_2 | \mathbf{x})$$

$$\frac{P(\omega_1 | \mathbf{x})}{P(\omega_2 | \mathbf{x})} > \frac{(\lambda_{12} - \lambda_{22})}{(\lambda_{21} - \lambda_{11})} \Rightarrow \mathbf{x} \in \omega_1 \quad P(\omega_j | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_j)P(\omega_j)}{p(\mathbf{x})}$$

$$\frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} > \frac{(\lambda_{12} - \lambda_{22})P(\omega_2)}{(\lambda_{21} - \lambda_{11})p(\omega_1)} \Rightarrow \mathbf{x} \in \omega_1$$

似然比

不依赖观测值x的阈值



$$\frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} > \theta \Rightarrow x \in \omega_1$$

在采用0-1损失函数时，**最小风险贝叶斯决策**就等价于**最小错误率贝叶斯决策**。

0-1损失函数

$$\lambda(\alpha_i, \omega_j) = \begin{cases} 0, & i = j \\ 1, & i \neq j \end{cases}$$

对于正确决策（即 $i=j$ ）， $\lambda(\alpha_i, \omega_j)=0$ ，就是说没有损失；而对于任何错误决策，其损失均为1

贝叶斯分类器的其它版本

- 约束一定错误率（风险）：Neyman-Pearson准则；
- 先验概率 $P(\omega_i)$ 未知：极小化极大准则；
- 某些特征缺失的决策：
- 连续出现的模式之间统计相关的决策：

Neyman-Pearson准则

1.问题的提出:

(1)某些二类判决问题, 某一种错误较另一种错误更为重要—危害更为严重。

(2)先验概率未知。


2.基本思想:

严格限制较重要的一类错误概率, 在令其等于某常数的约束下使另一类误判概率最小。

在癌症诊断中, 把癌症误判为正常的损失更为严重, 要求这种误判错误率 $P_2(e) = \varepsilon_0$, ε_0 是一个很小的常数

在这样的约束下, 求把正常误判为癌症的错误率 $P_1(e)$ 极小值


3.决策规则



$$\varepsilon_{21} = P_2(e) = \int_{R_1} p(\mathbf{x} | \omega_2) d\mathbf{x} \quad \varepsilon_{12} = P_1(e) = \int_{R_2} p(\mathbf{x} | \omega_1) d\mathbf{x}$$

限定 $\varepsilon_{21} = \varepsilon_0$ 时，最小化 ε_{12} ：构造 **Lagrange** 乘子

$$r = \varepsilon_{12} + \lambda(\varepsilon_{21} - \varepsilon_0)$$

$$\int_{R_2} p(\mathbf{x} | \omega_1) d\mathbf{x} = 1 - \int_{R_1} p(\mathbf{x} | \omega_1) d\mathbf{x}$$


$$\begin{aligned} r &= \int_{R_2} p(\mathbf{x} | \omega_1) d\mathbf{x} + \lambda \left[\int_{R_1} p(\mathbf{x} | \omega_2) d\mathbf{x} - \varepsilon_0 \right] \\ &= (1 - \lambda \varepsilon_0) + \int_{R_1} [\lambda p(\mathbf{x} | \omega_2) - p(\mathbf{x} | \omega_1)] d\mathbf{x} \end{aligned}$$

■由此式分别对 \mathbf{x} 和 λ 求导，令 $\frac{\partial r}{\partial \mathbf{x}} = 0$ $\frac{\partial r}{\partial \lambda} = 0$ 有

$$\lambda = \frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} \quad \int_{R_1} p(\mathbf{x} | \omega_2) d\mathbf{x} = \varepsilon_0$$

满足 $\lambda = \frac{P(\mathbf{x} | \omega_1)}{P(\mathbf{x} | \omega_2)}$ 的最佳值 λ 和满足 $\int_{R_1} P(\mathbf{x} | \omega_2) d\mathbf{x} = \varepsilon_0$ 的边界面就能使 r 极小。

N-P决策规则

如果： $\frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} > \lambda$ 则： $\mathbf{x} \in \begin{cases} \omega_1 \\ \omega_2 \end{cases}$

N-P决策规则归结为找阈值 λ 。

当 $\frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} = \lambda$ 时, λ 作 $R_1 R_2$ 的分界线.

$$\varepsilon_2 = \int_{-\infty}^{\lambda} p(\mathbf{x} | \omega_2) dx,$$



λ 为 ε_2 的函数在取 ε_2 为常数时, λ 可确定,

这时 ε_2 一定 ε_1 最小

λ 的确定:

$$\varepsilon_0 = \varepsilon_{21} = \int_{-\infty}^{\lambda} p(l/\omega_2) dl$$

通过建立 $\lambda - \varepsilon$ 对照表确定。



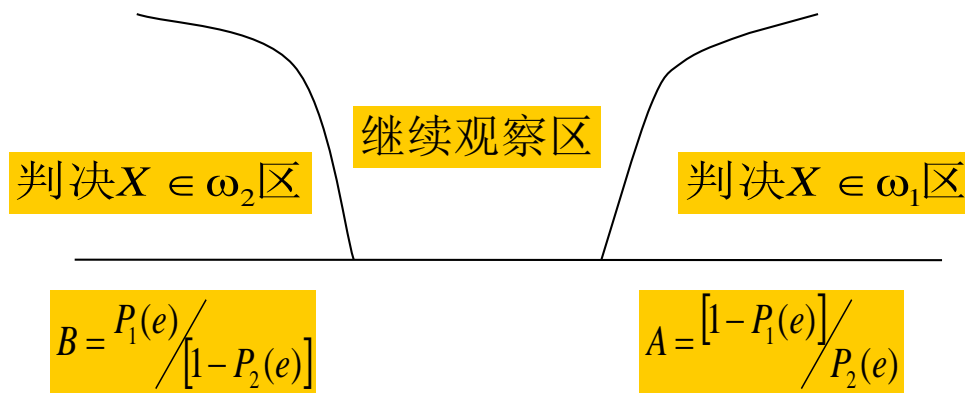
4. 最小错误率贝叶斯决策规则与N-P决策

| | |
|-------|---|
| 最小错误率 | $\frac{p(\mathbf{x} \omega_1)}{p(\mathbf{x} \omega_2)} > \frac{P(\omega_2)}{p(\omega_1)} \Rightarrow \mathbf{x} \in \omega_1$ |
| 最小风险 | $\frac{p(\mathbf{x} \omega_1)}{p(\mathbf{x} \omega_2)} > \frac{(\lambda_{12} - \lambda_{22})P(\omega_2)}{(\lambda_{21} - \lambda_{11})p(\omega_1)} \Rightarrow \mathbf{x} \in \omega_1$ |
| N-P决策 | $\frac{p(\mathbf{x} \omega_1)}{p(\mathbf{x} \omega_2)} > \lambda, \quad \varepsilon_2 = \int_{-\infty}^{\lambda} p(l \omega_2) dl \Rightarrow \mathbf{x} \in \omega_1$ |
| | 似然比 \longleftrightarrow 不依赖观测值x的阈值 |

序贯分类决策

- 在许多实际问题中，观察实际上是序贯的。
- 对样品进行第 i 次观察获取一序列特征为： $X=(x_1, x_2, \dots, x_i)^T$ 则对于 ω_1 , ω_2 两类问题,
 - 若 $X \in \omega_1$ ，则判决完毕
 - 若 $X \in \omega_2$ ，则判决完毕
 - 若 X 不属 ω_1 也不属 ω_2 ，则不能判决，进行第 $i+1$ 次观察，得 $X=(x_1, x_2, \dots, x_i, x_{i+1})^T$ ，再重复上面的判决，直到所有的样品分类完毕为止。
- 使那些在二类边界附近的样本不会因某种偶然的微小变化而误判

➤序贯分类决策规则:



$$\left\{ \begin{array}{l} \frac{P_i(X/\omega_1)}{P_i(X/\omega_2)} \geq A = \frac{1 - P_1(e)}{P_2(e)} \text{ 时 } X \in \omega_1 \\ \frac{P_i(X/\omega_1)}{P_i(X/\omega_2)} \leq B = \frac{P_1(e)}{1 - P_2(e)} \text{ 时 } X \in \omega_2 \\ B < \frac{P_i(X/\omega_1)}{P_i(X/\omega_2)} < A \text{ 时, 继续观察} \end{array} \right.$$


- 上下门限A、B是由设计给定的错误概率 $P_1(e)$, $P_2(e)$ 来确定的, Wald 已证明, 观察次数不会很大, 它收敛的很快。

高斯分布的贝叶斯分类器

单变量正态分布密度函数（高斯分布）：

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right]$$

$$p(x) \sim N(\mu, \sigma^2)$$



最大熵：在均值、方差确定的各种分布中，正态分布的熵最大

$$-\int p(x) \ln p(x) dx$$

中心极限定理：大量小的、独立随机分布的总和等效为正态分布


多元正态分布函数

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})\right]$$

$$p(\mathbf{x}) \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

$$\text{均值: } \boldsymbol{\mu} = E(\mathbf{x}) = \int \mathbf{x} p(\mathbf{x}) d\mathbf{x}$$

$$\mu_i = E(x_i)$$



$$\text{协方差矩阵: } \boldsymbol{\Sigma} = E\left((\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^t\right) = \int (\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^t p(\mathbf{x}) d\mathbf{x}$$

$$\sigma_{ij} = E\left((x_i - \mu_i)(x_j - \mu_j)\right)$$

多元正态类条件概率密度

$$p(\mathbf{x}|\omega_i) \sim N(\boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$$

$$p(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}_i|^{1/2}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i)\right]$$

正态分布的判别函数

贝叶斯判别函数可以写成对数形式：

$$g_i(\mathbf{x}) = \ln p(\mathbf{x}|\omega_i) + \ln P(\omega_i)$$

$$\text{其中 } p(\mathbf{x}|\omega_i) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}_i|^{1/2}} \exp\left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i)\right]$$

类条件概率密度函数为正态分布时：

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$

情况一： $\Sigma_i = \sigma^2 \mathbf{I}, P(\omega_i) = \frac{1}{c}$ 距离分类器

- 判别函数可以写成：

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \Sigma_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i)$$



$$g_i(\mathbf{x}) = -(\mathbf{x} - \boldsymbol{\mu}_i)^t (\mathbf{x} - \boldsymbol{\mu}_i) = -\|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

- 此分类器称为距离分类器，判别函数可以用待识模式 \mathbf{x} 与类别均值 $\boldsymbol{\mu}_i$ 之间的距离表示：

$$g_i(\mathbf{x}) = -d(\mathbf{x}, \boldsymbol{\mu}_i)$$

情况二： $\Sigma_i = \Sigma$ 线性分类器

判别函数可以写成：

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \Sigma_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\Sigma_i| + \ln P(\omega_i)$$




$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) + \ln P(\omega_i)$$



$$g_i(\mathbf{x}) = \boldsymbol{\mu}_i^t \Sigma^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_i^t \Sigma^{-1} \boldsymbol{\mu}_i + \ln P(\omega_i) = \mathbf{w}_i^t \mathbf{x} + w_{i0}$$



线性分类器

- 两类问题，1维特征，先验概率相同时：




线性分类器

两类问题，高维特征，先验概率相同时：





线性分类器

两类问题，1维特征，先验概率不同时：



线性分类器

两类问题，高维特征，先验概率不同时：



情况三： Σ_i 任意

判别函数可以写成：





$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^t \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{d}{2} \ln 2\pi - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$







$$g_i(\mathbf{x}) = -\frac{1}{2} \mathbf{x}^t \boldsymbol{\Sigma}_i^{-1} \mathbf{x} + \boldsymbol{\mu}_i^t \boldsymbol{\Sigma}_i^{-1} \mathbf{x} + \left(-\frac{1}{2} \boldsymbol{\mu}_i^t \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i) \right)$$

分类界面为2次曲线（面）

二次分类曲线



二次分类曲面



例:正态分布二次分类曲面举例


$$g_i(\mathbf{x}) = -\frac{1}{2}\mathbf{x}^t \boldsymbol{\Sigma}_i^{-1} \mathbf{x} + \boldsymbol{\mu}_i^t \boldsymbol{\Sigma}_i^{-1} \mathbf{x} + \left(-\frac{1}{2} \boldsymbol{\mu}_i^t \boldsymbol{\Sigma}_i^{-1} \boldsymbol{\mu}_i - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i) \right)$$

$$p(\omega_1) = p(\omega_2) = 0.5$$

$$\boldsymbol{\mu}_1 = \begin{bmatrix} 3 \\ 6 \end{bmatrix}; \quad \boldsymbol{\Sigma}_1 = \begin{pmatrix} 1/2 & 0 \\ 0 & 2 \end{pmatrix}$$

$$\boldsymbol{\mu}_2 = \begin{bmatrix} 3 \\ -2 \end{bmatrix}; \quad \boldsymbol{\Sigma}_2 = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

$$\boldsymbol{\Sigma}_1^{-1} = \begin{pmatrix} 2 & 0 \\ 0 & 1/2 \end{pmatrix} \quad \boldsymbol{\Sigma}_2^{-1} = \begin{pmatrix} 1/2 & 0 \\ 0 & 1/2 \end{pmatrix}$$



$$g_1(\mathbf{x}) = g_2(\mathbf{x}) \Rightarrow x_2 = 3.514 - 1.125x_1 + 0.1875x_1^2$$

朴素贝叶斯分类器

难估计协方差矩阵：特征的维数较高、训练样本数量较少时，无法有效估计协方差矩阵

假设各维独立：假设各维特征服从相互独立的高斯分布

$$p(\mathbf{x}|\omega_i) = \prod_{j=1}^d p(x_j|\omega_i) = \prod_{j=1}^d \left\{ \frac{1}{\sqrt{2\pi}\sigma_{ij}} \exp \left[-\frac{(x_j - \mu_{ij})^2}{2\sigma_{ij}^2} \right] \right\}$$

对数判别函数为

$$g_i(\mathbf{x}) = \ln p(\mathbf{x}|\omega_i) + \ln P(\omega_i)$$

x_j : 第 j 维特征

ω_i : 第 i 类别

$$= \sum_{j=1}^d \left\{ -\frac{1}{2} \ln 2\pi - \ln \sigma_{ij} - \frac{(x_j - \mu_{ij})^2}{2\sigma_{ij}^2} \right\} + \ln P(\omega_i)$$

$$= -\frac{d}{2} \ln 2\pi - \sum_{j=1}^d \ln \sigma_{ij} - \sum_{j=1}^d \frac{(x_j - \mu_{ij})^2}{2\sigma_{ij}^2} + \ln P(\omega_i)$$

改进二次判别函数 (MQDF)

协方差矩阵不可逆、或特征值太小计算不稳定时怎么办？

对协方差矩阵进行特征值分解（主成分分析思想）

保留大特征值对应的主要成分

用常数替代小特征值，保证计算稳定

协方差矩阵特征值分解：

$$\Sigma = \mathbf{Q}\Lambda\mathbf{Q}^T = \sum_{j=1}^d \lambda_j \mathbf{v}_j \mathbf{v}_j^T$$

λ_j : 特征值
 \mathbf{v}_j : 特征向量

协方差矩阵的逆：

$$\Sigma_i^{-1} = \left(\mathbf{Q}_i \Lambda_i \mathbf{Q}_i^T \right)^{-1} = \mathbf{Q}_i \Lambda_i^{-1} \mathbf{Q}_i^T = \sum_{j=1}^d \frac{1}{\lambda_{ij}} \mathbf{v}_{ij} \mathbf{v}_{ij}^T$$

$$g_i(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \cancel{\frac{d}{2} \ln 2\pi} - \frac{1}{2} \ln |\boldsymbol{\Sigma}_i| + \ln P(\omega_i)$$

$$= -\frac{1}{2} \sum_{j=1}^d \frac{1}{\lambda_{ij}} (\mathbf{x} - \boldsymbol{\mu}_i)^T \mathbf{v}_{ij} \mathbf{v}_{ij}^T (\mathbf{x} - \boldsymbol{\mu}_i) - \frac{1}{2} \sum_{j=1}^d \ln \lambda_{ij} + \ln P(\omega_i)$$

$\boldsymbol{\Sigma}_i^{-1} = \sum_{j=1}^d \frac{1}{\lambda_{ij}} \mathbf{v}_{ij} \mathbf{v}_{ij}^T$
 $|\boldsymbol{\Sigma}_i| = \prod_{j=1}^d \lambda_{ij}$

$$= -\frac{1}{2} \sum_{j=1}^d \frac{1}{\lambda_{ij}} \left[(\mathbf{x} - \boldsymbol{\mu}_i)^T \mathbf{v}_{ij} \right]^2 - \frac{1}{2} \sum_{j=1}^d \ln \lambda_{ij} + \ln P(\omega_i)$$

令 $y_j = (\mathbf{x} - \boldsymbol{\mu}_i)^T \mathbf{v}_{ij}$, 代表 \mathbf{x} 在新坐标系上第 j 轴的坐标

只保留前 k 个最大的特征值, 其他用一小正数 δ_i 替代

$$= -\frac{1}{2} \sum_{j=1}^k \frac{y_j^2}{\lambda_{ij}} - \frac{1}{2\delta_i} \sum_{j=k+1}^d y_j^2 - \frac{1}{2} \sum_{j=1}^k \ln \lambda_{ij} - \frac{d-k}{2} \ln \delta_i + \ln P(\omega_i)$$

$$= \sum_{j=1}^d y_j^2 - \sum_{j=1}^k y_j^2 = \|\mathbf{x} - \boldsymbol{\mu}_i\|^2 - \sum_{j=1}^k y_j^2$$

$$= -\frac{1}{2} \sum_{j=1}^k \frac{y_j^2}{\lambda_{ij}} - \frac{1}{2\delta_i} \left(\|\mathbf{x} - \boldsymbol{\mu}_i\|^2 - \sum_{j=1}^k y_j^2 \right) - \frac{1}{2} \sum_{j=1}^k \ln \lambda_{ij} - \frac{d-k}{2} \ln \delta_i + \ln P(\omega_i)$$

$$g_i(\mathbf{x}) = -\frac{1}{2} \sum_{j=1}^k \frac{y_j^2}{\lambda_{ij}} - \frac{1}{2\delta_i} \left(\|\mathbf{x} - \boldsymbol{\mu}_i\|^2 - \sum_{j=1}^k y_j^2 \right) \\ - \frac{1}{2} \sum_{j=1}^k \ln \lambda_{ij} - \frac{d-k}{2} \ln \delta_i + \ln P(\omega_i)$$

- 降低算法、存储复杂度 $k \ll d$

计算 k 维坐标 $y_j = (\mathbf{x} - \boldsymbol{\mu}_i)^t \mathbf{v}_{ij}$, 计算一次向量范数 $\|\mathbf{x} - \boldsymbol{\mu}_i\|^2$

- 先验概率的估计

$$P(\omega_i) = n_i / n$$

- 保留特征值个数 k 的选定:

$$\sum_{k=1}^j \lambda_{ik} / \sum_{k=1}^d \lambda_{ik} \geq 95\%$$

作业：态分布的N-P判决

N-P判决举例： 设两类问题中，二维样本均为正态分布，有 $\mu_1 = (-1, 0)^t$, $\mu_2 = (1, 0)^t$, $\Sigma_1 = \Sigma_2 = \mathbf{I}$, 取 $\varepsilon_{21} = 0.046$, 求N-P判决界面

